UNIBALSAS Centro Universitário

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

CURSO	Análise e Desenvolvimento de Sistemas	**PERÍODO**	2026.2
UNI. CURRICULAR	Big Data e Ciência de Dados		
PROFESSOR	Alex Rogaleski Marques		
ACADÊMICOS	Gustavo Noleto, Jardel Oliveira, Miquéias do Nascimento e Wallaci Araujo		

TED 03 – Modelagem Preditiva e Machine Learning
Agente de Carreiras IA

1. Definição do problema de Machine Learning

O projeto Agente de Carreira IA tem como objetivo auxiliar pessoas que buscam o primeiro emprego, recolocação profissional ou novas oportunidades na organização de suas informações profissionais e na preparação para processos seletivos.

Conforme definido nas etapas anteriores, muitos candidatos possuem experiências, conhecimentos e habilidades, mas encontram dificuldades para apresentá-los de maneira clara e organizada em currículos, cartas de apresentação e entrevistas.

Nesse contexto, a modelagem de Machine Learning foi direcionada à identificação e previsão de competências profissionais relacionadas a determinadas ocupações.

O problema tratado consiste em receber informações textuais sobre uma ocupação, como seu título, denominações alternativas e descrição, e estimar quais competências essenciais estão associadas a ela.

A proposta é que o modelo possa contribuir para que o Agente de Carreira IA compreenda melhor o cargo desejado pelo candidato e utilize as competências relacionadas a essa ocupação como referência para organizar informações profissionais, contextualizar sugestões e apoiar a preparação para entrevistas.

Diferentemente de um sistema de avaliação de candidatos, o modelo não pretende determinar se uma pessoa possui determinada competência ou se está apta para uma contratação. Sua finalidade é identificar competências normalmente associadas à ocupação informada.

2. Tipo de abordagem adotada

Foi adotada uma abordagem de **classificação multirrótulo (multi-label classification)**.

Essa escolha ocorre porque uma mesma ocupação pode estar relacionada a várias competências essenciais simultaneamente. Portanto, o modelo não precisa escolher apenas uma classe, mas identificar um conjunto de competências que podem estar associadas ao cargo informado.

Por exemplo, uma ocupação pode estar relacionada a competências como comunicação, organização do trabalho, resolução de problemas e utilização de equipamentos específicos.

Na classificação multirrótulo, cada competência é tratada como uma possibilidade de previsão independente. Assim, uma mesma entrada pode receber várias previsões positivas.

Essa abordagem é adequada ao problema porque representa melhor a natureza das relações existentes entre ocupações e competências profissionais.

3. Preparação dos dados

A preparação dos dados foi realizada a partir dos arquivos processados anteriormente, considerando principalmente as informações de ocupações e as relações entre ocupações e competências disponíveis na base ESCO.

Foram utilizados os seguintes arquivos:

- `ESCO_occupations_processed.csv`: contém informações relacionadas às ocupações, incluindo títulos e descrições.
- `ESCO_relations_processed.csv`: contém as relações entre ocupações e conhecimentos, habilidades e competências profissionais.

3.1. Seleção e organização dos registros

Inicialmente, foram carregados os arquivos processados e verificadas as relações entre ocupações e competências.

As ocupações foram identificadas por meio de seus identificadores únicos (`conceptUri`), sendo removidas duplicidades de identificadores para evitar que uma mesma ocupação fosse representada repetidamente na etapa de modelagem.

Em seguida, foram selecionadas as relações classificadas como essenciais e pertencentes ao tipo competência.

Após os filtros e tratamentos, foram obtidos os seguintes resultados:

Informação	Quantidade
Ocupações no arquivo original	3.043
Identificadores únicos de ocupações	3.039
Relações essenciais de competências	51.155
Ocupações incluídas no conjunto final de modelagem	3.037

Foram mantidas no conjunto de modelagem as ocupações que possuíam pelo menos uma competência essencial associada e informações textuais disponíveis para representar sua descrição.

3.2. Construção dos dados de entrada

Para representar textualmente cada ocupação, foram utilizadas três informações principais:

- Título preferencial (`preferredLabel`);
- Títulos alternativos (`altLabels`);
- Descrição da ocupação (`description`).

Esses campos foram combinados em uma única variável textual denominada `texto_entrada`.

A combinação permite que o modelo considere diferentes formas de denominar uma ocupação e informações descritivas sobre suas características.

3.3. Construção das variáveis-alvo

As competências essenciais relacionadas a cada ocupação foram organizadas como um conjunto de rótulos.

Como uma ocupação pode possuir várias competências, foi utilizada a transformação multirrótulo por meio do `MultiLabelBinarizer`.

Esse procedimento transforma os conjuntos de competências em uma matriz binária, na qual cada coluna representa uma competência e cada linha representa uma ocupação.

O valor 1 indica que determinada competência está associada à ocupação, enquanto o valor 0 indica que ela não está presente entre os rótulos considerados.

3.4. Transformação textual

Para transformar os textos em representações numéricas, foi utilizado o método TF-IDF (*Term Frequency–Inverse Document Frequency*).

Essa técnica atribui pesos aos termos de acordo com sua frequência no texto e sua ocorrência no conjunto de documentos. Dessa forma, palavras relevantes para diferenciar as ocupações recebem maior importância na representação numérica.

Também foram utilizados unigramas e bigramas, permitindo considerar tanto palavras individuais quanto combinações de duas palavras.

4. Seleção de variáveis

As variáveis utilizadas foram divididas em variáveis de entrada e variável-alvo.

4.1. Variáveis de entrada

Variável	Descrição	Justificativa
`preferredLabel`	Título principal da ocupação	Identifica a profissão ou função
`altLabels`	Denominações alternativas	Permite considerar diferentes nomes utilizados para uma mesma ocupação
`description`	Descrição da ocupação	Acrescenta contexto sobre as características profissionais

As três variáveis foram combinadas em `texto_entrada`, que representa a entrada textual utilizada pelo modelo.

A escolha dessas informações considera que o nome de uma ocupação, isoladamente, pode não conter contexto suficiente para identificar suas competências. A descrição e os títulos alternativos ampliam a representação textual da profissão.

4.2. Variável-alvo

A variável-alvo corresponde ao conjunto de competências essenciais associadas a cada ocupação.

Cada competência é representada por um rótulo independente na classificação multirrótulo.

Para os experimentos, foram selecionadas as 30, 50 e 100 competências mais frequentes no conjunto de treinamento. Essa estratégia permitiu comparar o desempenho do modelo com diferentes quantidades de classes.

A seleção das competências foi realizada com base exclusivamente nos dados de treinamento, evitando utilizar a distribuição de rótulos do conjunto de teste para essa decisão.

5. Técnicas utilizadas

Foram utilizadas duas técnicas principais:

- TF-IDF para representação numérica dos textos;
- Regressão Logística com estratégia One-vs-Rest para classificação multirrótulo.

5.1. TF-IDF

O TF-IDF foi utilizado para converter as informações textuais das ocupações em vetores numéricos que podem ser processados pelo algoritmo de classificação.

A configuração utilizada foi:

Parâmetro	Valor
`ngram_range`	`(1, 2)`
`min_df`	`2`
`max_features`	`50000`
`sublinear_tf`	`True`

A configuração permite considerar palavras isoladas e combinações de duas palavras, desconsiderar termos com ocorrência muito baixa e limitar o tamanho máximo do vocabulário.

Após o treinamento, o vocabulário efetivamente utilizado apresentou 17.793 termos.

5.2. Regressão Logística com One-vs-Rest

Foi utilizada a Regressão Logística por meio da estratégia One-vs-Rest (`OneVsRestClassifier`).

Essa estratégia cria um classificador binário para cada competência considerada. Cada classificador aprende a distinguir as ocupações associadas à competência daquelas que não possuem essa associação.

A configuração utilizada foi:

Parâmetro	Valor
Algoritmo	Regressão Logística

Parâmetro	Valor
Estratégia	One-vs-Rest
max_iter	1000
C	2.0
class_weight	balanced
solver	liblinear

A opção class_weight="balanced" foi utilizada para ajustar os pesos das classes considerando suas frequências, ajudando a lidar com diferenças na quantidade de exemplos positivos e negativos.

6. Justificativa da escolha das técnicas

A escolha do TF-IDF ocorreu porque o problema utiliza informações textuais sobre ocupações e precisa transformar esses textos em representações numéricas para que possam ser processados por um algoritmo de Machine Learning.

O método também permite considerar palavras e combinações de palavras que podem ser importantes para diferenciar ocupações.

A Regressão Logística foi selecionada por ser um algoritmo de classificação supervisionada que pode estimar a probabilidade de uma classe estar associada a determinada entrada.

A estratégia One-vs-Rest permite adaptar esse algoritmo ao problema multirrótulo, treinando um classificador para cada competência.

Essa combinação foi considerada adequada para um primeiro experimento de modelagem, por permitir implementar uma solução supervisionada, avaliar diferentes quantidades de competências e obter estimativas individuais para cada rótulo.

A escolha também favorece a interpretação dos resultados e a possibilidade de realizar melhorias posteriores, como testar outras formas de representação textual e outros algoritmos de classificação.

7. Processo de treinamento e avaliação

O conjunto final de dados foi dividido em duas partes:

Conjunto	Quantidade de ocupações	Proporção
Treinamento	2.429	80%
Teste	608	20%
Total	3.037	100%

Foi utilizado o método train_test_split, com os seguintes parâmetros:

- test_size=0.20;

- `random_state=42`;
- `shuffle=True`.

A divisão aleatória permite utilizar uma parte dos registros para o aprendizado do modelo e reservar outra parte para avaliar seu desempenho em ocupações que não participaram do treinamento.

O parâmetro `random_state=42` foi definido para permitir a reprodução da mesma divisão dos dados em novas execuções.

Após a divisão, o TF-IDF foi ajustado somente com os textos de treinamento. Os textos de teste foram transformados utilizando o vocabulário aprendido no treinamento.

Da mesma forma, a seleção das competências mais frequentes foi realizada considerando apenas o conjunto de treinamento.

Foram realizados três experimentos, variando a quantidade de competências utilizadas como rótulos:

- Experimento 1: 30 competências;
- Experimento 2: 50 competências;
- Experimento 3: 100 competências.

Essa comparação permitiu observar como o desempenho se comporta quando o modelo precisa identificar um conjunto maior de competências.

8. Métricas de avaliação

Foram utilizadas métricas adequadas a problemas de classificação multirrótulo.

8.1. Precisão (Precision)

A precisão representa a proporção de previsões positivas que realmente estavam associadas às competências esperadas.

Essa métrica ajuda a avaliar quantas das competências sugeridas pelo modelo estavam corretas.

8.2. Revocação (Recall)

A revocação representa a proporção das competências esperadas que foram identificadas corretamente pelo modelo.

Essa métrica permite avaliar quantas competências relevantes o modelo conseguiu recuperar.

8.3. F1 Micro

O F1 Micro calcula a combinação entre precisão e revocação considerando conjuntamente as previsões de todas as competências.

Essa métrica permite observar o desempenho geral do modelo considerando o conjunto de decisões realizadas.

8.4. F1 Macro

O F1 Macro calcula o F1 individual de cada competência e depois realiza a média aritmética desses valores.

Essa métrica permite observar o desempenho médio entre as competências, atribuindo o mesmo peso a cada uma delas, independentemente de sua frequência.

8.5. F1 Samples

O F1 Samples calcula o F1 para cada ocupação, considerando o conjunto de competências esperadas e previstas para aquele registro, e depois realiza a média.

Essa métrica é especialmente relevante para o problema porque permite avaliar a qualidade do conjunto de competências previsto para cada ocupação.

A utilização conjunta dessas métricas permite analisar o desempenho geral do modelo e também observar diferenças entre competências e ocupações.

9. Resultados obtidos

Foram realizados três experimentos, variando a quantidade de competências selecionadas como possíveis rótulos.

9.1. Comparação entre os experimentos

Métrica	30 competências	50 competências	100 competências
F1 Micro	63,96%	66,74%	**68,63%**
F1 Macro	62,72%	66,60%	**69,27%**
Precisão Micro	62,08%	65,76%	**68,16%**
Revocação Micro	65,95%	67,74%	**69,10%**
F1 Samples	35,50%	38,00%	**38,07%**

Os resultados demonstram uma melhora progressiva nas métricas gerais conforme a quantidade de competências consideradas aumentou.

O experimento com 100 competências apresentou os melhores resultados entre as três configurações avaliadas.

A Figura 1 apresenta a evolução do F1 Micro, do F1 Macro e do F1 Samples conforme a quantidade de competências aumenta. Observa-se crescimento nas três métricas, e o F1 Samples permanece em patamar inferior às demais em todos os experimentos.

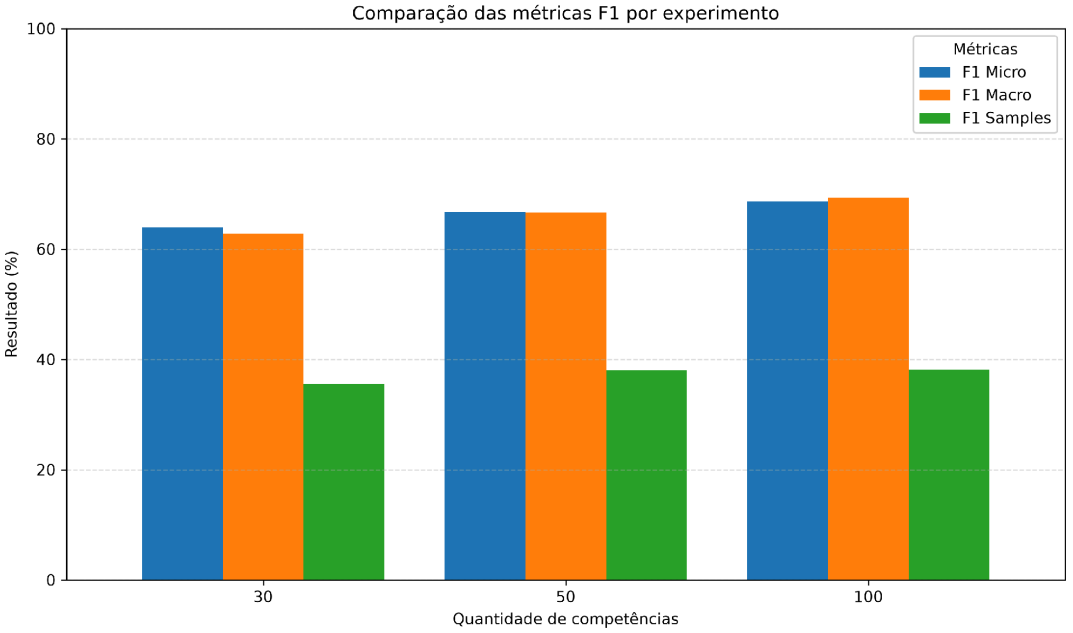


Figura 1 – Comparação das métricas F1 (Micro, Macro e Samples) por experimento.

A Figura 2 compara a precisão e a revocação nos três experimentos. Ambas aumentam com a quantidade de competências, e a revocação se mantém ligeiramente acima da precisão em todos os casos.

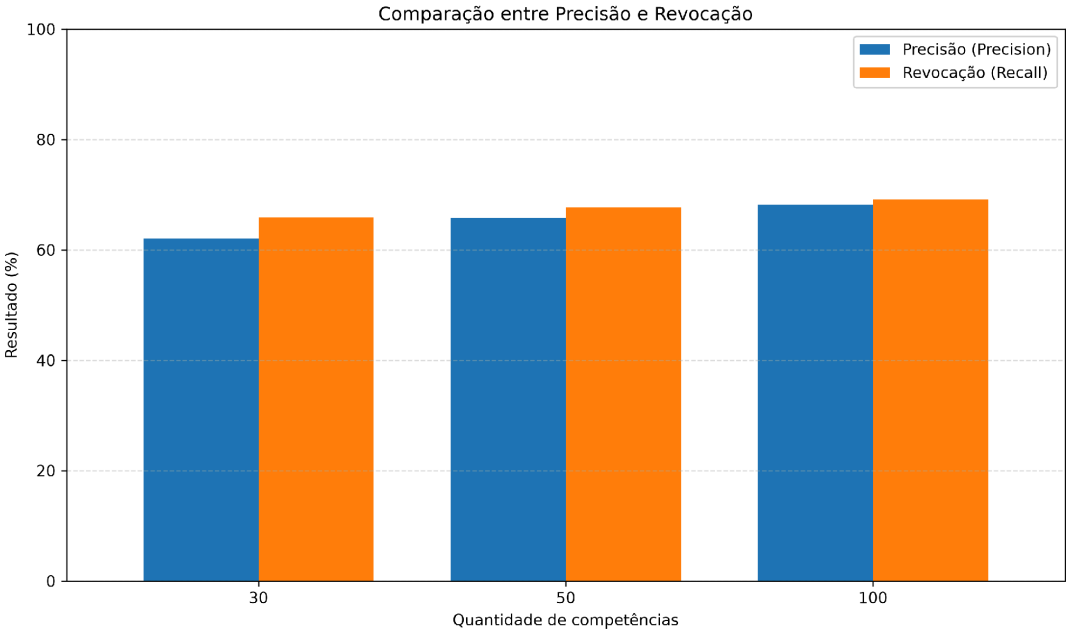


Figura 2 – Comparação entre precisão e revocação por experimento (30, 50 e 100 competências).

9.2. Resultado do melhor experimento

O experimento com 100 competências apresentou:

- F1 Micro: 68,63%;
- F1 Macro: 69,27%;
- Precisão Micro: 68,16%;
- Revocação Micro: 69,10%;
- F1 Samples: 38,07%.

O resultado de F1 Macro indica que, considerando as 100 competências avaliadas, a média dos valores individuais de F1 foi de aproximadamente 69,27%.

O F1 Samples, por sua vez, apresentou resultado inferior às métricas Micro e Macro. Isso indica que a correspondência entre o conjunto completo de competências previstas e o conjunto esperado para cada ocupação ainda representa um desafio para o modelo.

9.3. Desempenho individual das competências

Também foi realizada uma análise individual das 100 competências utilizadas no melhor experimento.

As métricas foram organizadas no arquivo `metricas_por_competencia.csv`, contendo:

- Identificador da competência;
- Nome da competência;
- Precisão;
- Revocação;
- F1;
- Suporte no conjunto de teste.

O resumo estatístico das métricas foi:

Estatística	Precisão	Revocação	F1	Suporte no teste
Quantidade	100	100	100	100
Média	0,7110	0,7066	0,6927	23,27
Desvio padrão	0,1995	0,1833	0,1706	10,58
Mínimo	0,2093	0,2000	0,2500	6
Mediana	0,7290	0,7101	0,6830	21
Máximo	1,0000	1,0000	1,0000	65

A distribuição dos resultados de F1 entre as competências foi:

Faixa de F1	Quantidade de competências
Abaixo de 40%	4
De 40% a menos de 50%	8
De 50% a menos de 60%	17

Faixa de F1	Quantidade de competências
De 60% a menos de 70%	24
De 70% a menos de 80%	20
De 80% a menos de 90%	12
De 90% a 100%	15

A Figura 3 ilustra essa distribuição. A faixa de 60% a 70% concentra o maior número de competências (24), enquanto 4 competências ficaram abaixo de 40% e 15 alcançaram F1 entre 90% e 100%.

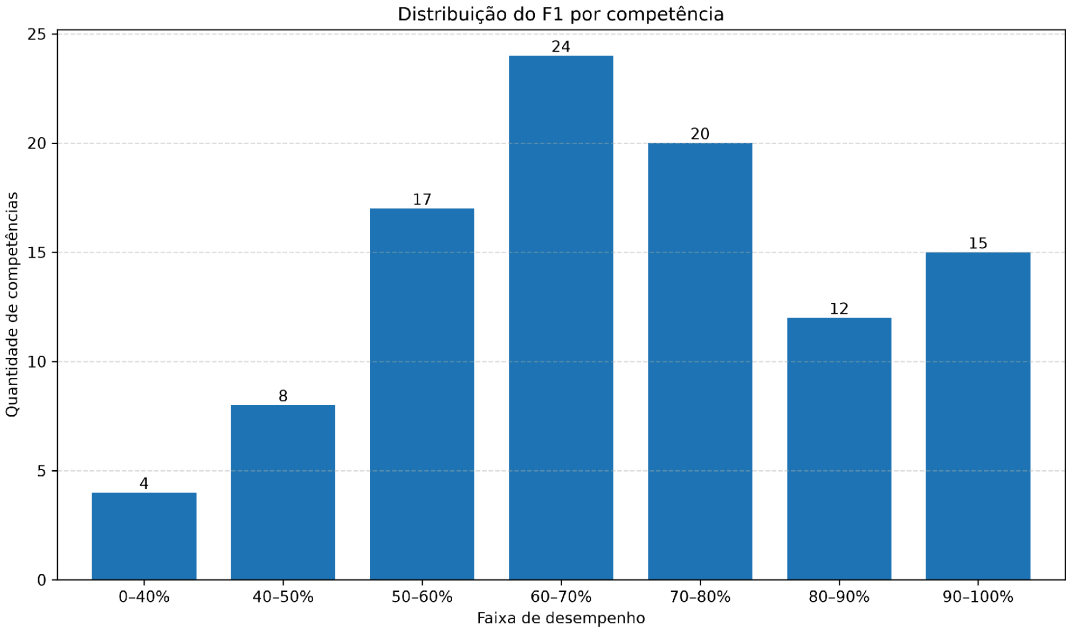


Figura 3 – Distribuição do F1 por competência, agrupado por faixa de desempenho (100 competências).

Ao todo, 47 competências apresentaram F1 igual ou superior a 70%, enquanto 59 apresentaram F1 igual ou superior a 60%.

Os resultados demonstram que o desempenho não foi uniforme entre as competências. Algumas apresentaram resultados elevados, enquanto outras tiveram maior dificuldade de identificação.

9.4. Exemplos de competências com melhor desempenho

Entre as competências com maiores valores de F1, destacam-se:

Competência	Precisão	Revocação	F1
Planear operações de transporte	100%	100%	100%
Estabelecer um relacionamento com pessoas de diferentes contextos culturais	100%	100%	100%
Monitorizar o desempenho do mercado internacional	100%	100%	100%
Preparar aulas	100%	96%	97,96%
Assegurar conformidade com legislação aduaneira	94,74%	100%	97,30%

Esses resultados demonstram que o modelo conseguiu identificar corretamente algumas competências dentro do conjunto de teste, embora o desempenho elevado em determinadas classes não signifique que o mesmo comportamento ocorrerá em todas as ocupações.

9.5. Exemplos de competências com menor desempenho

Algumas competências apresentaram valores inferiores de F1:

Competência	Precisão	Revocação	F1
Assegurar a segurança pública	33,33%	20%	25%
Usar equipamento de proteção adequado	20,93%	42,86%	28,13%
Seguir as normas da empresa	23,08%	46,15%	30,77%
Assegurar o cumprimento da legislação ambiental	31,25%	41,67%	35,71%
Utilizar equipamento de proteção pessoal	64,29%	36%	46,15%

Esses exemplos indicam que determinadas competências apresentam maior dificuldade de classificação, possivelmente devido às características dos textos, à distribuição dos exemplos e à semelhança entre diferentes ocupações.

9.6. Análise da relação entre suporte e desempenho

Foi realizada uma análise para verificar se a quantidade de exemplos de cada competência no conjunto de teste apresentava relação com seu desempenho em F1.

Foram calculadas as correlações de Pearson e Spearman.

Medida	Resultado
Correlação de Pearson	-0,0264
Correlação de Spearman	-0,0050

Os valores ficaram próximos de zero, indicando que não foi observada uma associação relevante entre a quantidade de exemplos no conjunto de teste e o desempenho em F1 para as 100 competências analisadas.

Também foi realizada uma comparação por grupos de suporte:

Grupo de suporte	Quantidade de competências	Suporte médio	F1 médio
Até 10 exemplos	3	8,00	96,30%
11 a 20 exemplos	42	15,81	66,96%
21 a 30 exemplos	34	23,79	72,25%
Mais de 30 exemplos	21	39,52	65,23%

O grupo com até 10 exemplos apresentou F1 médio elevado, mas contém somente três competências. Portanto, esse resultado não deve ser interpretado como evidência de que poucas ocorrências favorecem o desempenho.

A análise indica que, neste experimento, a quantidade de exemplos isoladamente não explicou as diferenças de desempenho entre as competências. A correlação observada também não permite estabelecer relações de causa e efeito.

9.7. Diagnóstico da divisão entre treinamento e teste

Foi realizado um diagnóstico adicional para verificar a presença das competências selecionadas nos conjuntos de treinamento e teste.

Os resultados foram:

- 100 competências selecionadas;
- Nenhuma das 100 competências esteve ausente do conjunto de teste;
- Frequência mínima no treinamento: 53 exemplos;
- Frequência mínima no teste: 6 exemplos.

Esse diagnóstico demonstra que todas as competências selecionadas possuíam exemplos nos dois conjuntos.

Entretanto, a divisão utilizada foi aleatória e não aplicou uma técnica específica de estratificação multirrótulo. Assim, não é possível afirmar que a distribuição de todas as competências tenha sido proporcional entre treinamento e teste.

10. Interpretação dos resultados

Os resultados demonstram que o modelo conseguiu aprender associações entre as características textuais das ocupações e as competências essenciais relacionadas a elas.

A evolução das métricas entre os experimentos indica que a inclusão de mais competências permitiu ao modelo representar um conjunto mais amplo de informações profissionais sem reduzir o desempenho geral observado.

O melhor resultado foi obtido com 100 competências, alcançando F1 Micro de 68,63% e F1 Macro de 69,27%.

A proximidade entre essas duas métricas sugere que o desempenho geral e a média do desempenho individual das competências ficaram em níveis semelhantes nesse experimento.

Entretanto, a análise individual demonstrou diferenças importantes entre os rótulos. Algumas competências apresentaram F1 elevado, enquanto outras tiveram dificuldade de identificação.

Outro ponto relevante é o F1 Samples, que permaneceu abaixo das demais métricas. Isso demonstra que, apesar de o modelo conseguir identificar competências individualmente, ainda existe dificuldade em reproduzir com maior precisão o conjunto completo de competências associado a cada ocupação.

Portanto, os resultados indicam que o modelo apresenta potencial para apoiar a identificação de competências profissionais, mas ainda necessita de melhorias e avaliações adicionais antes de ser utilizado como única referência em uma aplicação prática.

10.1. Testes qualitativos com diferentes ocupações

Além das métricas quantitativas, foram realizados testes de previsão com quatro ocupações, utilizando o script `prever_competencias.py`.

Os testes tiveram como objetivo observar se as competências sugeridas apresentavam relação com o contexto profissional informado.

Operador de máquinas agrícolas

As competências previstas apresentaram relação com atividades e responsabilidades da ocupação, incluindo utilização de equipamentos, segurança e ergonomia.

Técnico em enfermagem

Foram identificadas competências relacionadas à legislação da área da saúde, escuta ativa, responsabilidade, comunicação e organização.

Motorista de caminhão

As previsões incluíram competências relacionadas à comunicação, segurança pública, comunicação com clientes e identificação de riscos. Também foi observada uma competência relacionada à segurança na construção civil, demonstrando que algumas previsões podem não ser totalmente adequadas ao contexto da ocupação.

Auxiliar administrativo

Foram sugeridas competências relacionadas à comunicação, atividades administrativas, elaboração de relatórios, organização de informações e relacionamento com clientes.

Os testes qualitativos demonstraram que o modelo conseguiu produzir sugestões coerentes em diferentes áreas profissionais, mas também apresentaram exemplos de previsões menos relacionadas à ocupação informada.

Esses testes são observações qualitativas e não substituem uma avaliação quantitativa independente.

11. Limitações identificadas

Apesar dos resultados obtidos, algumas limitações precisam ser consideradas.

11.1. Representação textual baseada em TF-IDF

O TF-IDF considera a frequência e a importância dos termos presentes nos textos, mas não compreende profundamente o significado das palavras.

Dessa forma, expressões semanticamente semelhantes podem ser representadas de maneiras diferentes, enquanto termos iguais podem aparecer em contextos profissionais distintos.

Essa característica pode dificultar a identificação de competências quando a relação entre ocupação e habilidade depende mais do contexto do que da correspondência textual.

11.2. Limitação da quantidade de competências

O modelo foi avaliado utilizando as 30, 50 e 100 competências mais frequentes no conjunto de treinamento.

Portanto, as previsões não representam todas as competências existentes na classificação. Competências menos frequentes ficaram fora dos experimentos realizados.

11.3. Divisão aleatória dos dados

A divisão entre treinamento e teste foi realizada de maneira aleatória, sem estratificação multirrótulo explícita.

Embora todas as 100 competências selecionadas tenham aparecido nos dois conjuntos, a distribuição dos exemplos não foi necessariamente proporcional.

Além disso, foi utilizado um único particionamento dos dados, o que limita a avaliação da estabilidade dos resultados.

11.4. Ausência de validação cruzada e teste externo

Os experimentos utilizaram uma divisão de treinamento e teste.

Não foi realizada validação cruzada nem avaliação com uma base externa independente. Dessa forma, os resultados representam o desempenho observado nessa divisão específica e não garantem o mesmo comportamento em outros conjuntos de dados.

11.5. Diferenças entre ocupações e competências

Algumas ocupações possuem descrições e características textuais semelhantes, mesmo quando estão relacionadas a competências diferentes.

Isso pode gerar previsões inadequadas, principalmente quando o modelo identifica palavras em comum, mas não consegue distinguir corretamente o contexto profissional.

11.6. Dependência da classificação utilizada

As competências aprendidas pelo modelo dependem da estrutura e das relações disponíveis na base utilizada.

Assim, possíveis limitações, ausências ou diferenças de classificação nos dados de origem também podem influenciar as previsões.

11.7. Não avaliação das competências individuais do candidato

O modelo identifica competências relacionadas a uma ocupação, mas não determina se o candidato possui essas competências.

Para essa finalidade, seria necessário analisar as informações fornecidas pelo próprio usuário e considerar o contexto de suas experiências, conhecimentos e atividades.

Portanto, as previsões devem ser tratadas como referências para apoiar a organização das informações profissionais, e não como comprovação das capacidades de uma pessoa.

11.8. Necessidade de melhorias futuras

Entre as possibilidades de evolução estão:

- Testar modelos que considerem melhor o contexto semântico dos textos;
- Avaliar outros algoritmos de classificação;
- Ampliar a quantidade de competências consideradas;
- Utilizar validação cruzada multirrótulo;
- Realizar avaliações com conjuntos de dados independentes;
- Melhorar a correspondência entre títulos de ocupações e descrições fornecidas em linguagem natural;
- Avaliar a qualidade das previsões com especialistas ou profissionais das áreas correspondentes.

12. Relação com o projeto e evolução do MVP

Os resultados da modelagem contribuem para a evolução do Agente de Carreira IA porque permitem acrescentar uma etapa de identificação de competências profissionais relacionadas à ocupação desejada pelo usuário.

O MVP foi definido para receber informações pessoais e profissionais em linguagem natural e utilizar Inteligência Artificial generativa para organizar essas informações e apoiar a preparação para processos seletivos.

Entre as funcionalidades previstas estão:

- Definição do cargo ou área profissional desejada;
- Geração de currículo;
- Geração de carta de apresentação;
- Entrevista simulada;
- Respostas por texto;
- Feedback da Inteligência Artificial.

O modelo de Machine Learning poderá atuar como um componente complementar nesse fluxo.

12.1. Identificação de competências relacionadas ao cargo

Quando o usuário informar o cargo desejado, o sistema poderá utilizar o modelo para sugerir competências essenciais relacionadas à ocupação.

Essas informações poderão ser utilizadas como referência para contextualizar as atividades, conhecimentos e habilidades associados à profissão.

12.2. Apoio à organização do currículo

As competências previstas poderão auxiliar a Inteligência Artificial generativa na identificação de temas profissionais relacionados às experiências fornecidas pelo candidato.

Por exemplo, quando o usuário descrever uma experiência de trabalho de maneira informal, o sistema poderá utilizar as competências relacionadas à ocupação como referência para organizar melhor a descrição.

Entretanto, o sistema deverá considerar somente informações efetivamente fornecidas ou confirmadas pelo candidato. Uma competência associada à ocupação não deverá ser automaticamente apresentada como uma habilidade comprovadamente possuída pelo usuário.

12.3. Apoio à geração da carta de apresentação

As competências relacionadas ao cargo desejado poderão contribuir para contextualizar a carta de apresentação, permitindo que o sistema considere características profissionais relevantes para a ocupação.

A geração deverá continuar baseada nas informações reais do candidato, evitando acrescentar experiências ou conhecimentos que não tenham sido informados.

12.4. Apoio à entrevista simulada

As competências identificadas poderão ser utilizadas como referência para elaborar perguntas relacionadas à ocupação pretendida.

Dessa maneira, o sistema poderá direcionar a entrevista simulada para temas profissionais associados ao cargo, tornando as perguntas mais contextualizadas.

O modelo não realiza sozinho a entrevista nem avalia a resposta do candidato. Essas atividades permanecem sob responsabilidade dos componentes de Inteligência Artificial generativa definidos para o MVP.

12.5. Integração com a arquitetura do projeto

A integração futura poderá utilizar uma arquitetura na qual o modelo de Machine Learning seja disponibilizado por um serviço Python, permitindo que o agente solicite previsões a partir do cargo e da descrição informados.

O resultado poderá ser utilizado pelo componente de Inteligência Artificial generativa para organizar sugestões, contextualizar respostas e produzir conteúdos relacionados à ocupação.

As probabilidades retornadas pelo modelo representam estimativas independentes para cada competência. Elas não devem ser interpretadas como percentuais de adequação profissional e não precisam somar 100%.

As sugestões deverão ser apresentadas como referências e permanecer sujeitas à confirmação do candidato.

13. Decisões técnicas e reprodutibilidade

Para facilitar a reprodução dos experimentos, foram organizados os scripts, arquivos processados e resultados da modelagem.

Os principais arquivos relacionados à etapa são:

Arquivo	Finalidade
modelagem.py	Executar a preparação específica para modelagem, treinamento e avaliação
prever_competencias.py	Carregar o modelo treinado e realizar previsões para novas ocupações
dataset_modelagem.csv	Armazenar o conjunto preparado para a modelagem
comparacao_modelos.csv	Registrar a comparação dos experimentos
metricas_por_competencia.csv	Armazenar as métricas individuais das competências
diagnostico_divisao.csv	Registrar o diagnóstico das competências nos conjuntos de treinamento e teste
modelo_competencias_esco.joblib	Armazenar o modelo treinado
configuracao_experimento.json	Registrar os parâmetros utilizados nos experimentos

O ambiente utiliza Python e bibliotecas específicas para processamento de dados e Machine Learning, incluindo pandas, scikit-learn e joblib.

A divisão aleatória foi configurada com `random_state=42`, permitindo reproduzir o particionamento utilizado nos experimentos.

Os resultados e configurações foram armazenados para facilitar futuras comparações e melhorias.

Repositório do projeto:

https://github.com/jardeloli/assitente-carreira-ia/tree/main/big_data

14. Conclusão

A etapa de modelagem preditiva permitiu desenvolver e avaliar um modelo de classificação multirrótulo capaz de identificar competências essenciais relacionadas a ocupações profissionais a partir de informações textuais.

Foram realizados três experimentos, considerando 30, 50 e 100 competências. O melhor resultado foi obtido com 100 competências, alcançando F1 Micro de 68,63% e F1 Macro de 69,27%.

A análise individual demonstrou que o desempenho varia entre as competências, indicando que algumas relações são mais facilmente identificadas pelo modelo do que outras. Os testes qualitativos também

mostraram previsões coerentes em diferentes ocupações, embora tenham sido observadas sugestões menos adequadas em determinados casos.

Os resultados indicam que a abordagem apresenta potencial para contribuir com o Agente de Carreira IA, principalmente na identificação de competências relacionadas ao cargo desejado e na contextualização das funcionalidades de geração de currículo, carta de apresentação e entrevista simulada.

Entretanto, as limitações identificadas demonstram que o modelo ainda necessita de melhorias, validações adicionais e avaliações com novos dados antes de ser utilizado como referência definitiva.

Conclui-se que a modelagem desenvolvida representa uma primeira etapa de aplicação de Machine Learning ao problema definido pelo projeto, fornecendo uma base técnica para a evolução do MVP e para futuras melhorias na identificação e organização de competências profissionais.